


# Sabiranje brojeva na slikama uz korišćenje veštačkih neuronskih mreža



# Ideja

## 1. Pretražiti ceo prostor slike

- Potrebno svaki deo slike proveriti
- Moguće lošije prepoznavanje brojeva na slici
- Performanse računara

## 2. Pretražiti odedene regione slike


- Potrebno pronaći regione
- Performanse računara

# Razvoj


Paralelno se razvija:

- Algoritam za određivanje regiona:
  - Uklanjanje šuma
  - Pronalaženje brojeva
  - Centriranje regiona
- Model neuronske mreže:
  - Obučavajući skup
  - Broj epoha
  - Aktivaciona funkcija
  - Broj slojeva neuronske mreže
  - ...


# Algoritam za određivanje regiona




# Grayscale



Globalni threshold  
 $\text{img\_gray} > 0.05$




# Opening – uništavanje tačaka square(3)



# Dilation – lakše određivanje regiona


## `disk(15)`






Tačnost: 23%

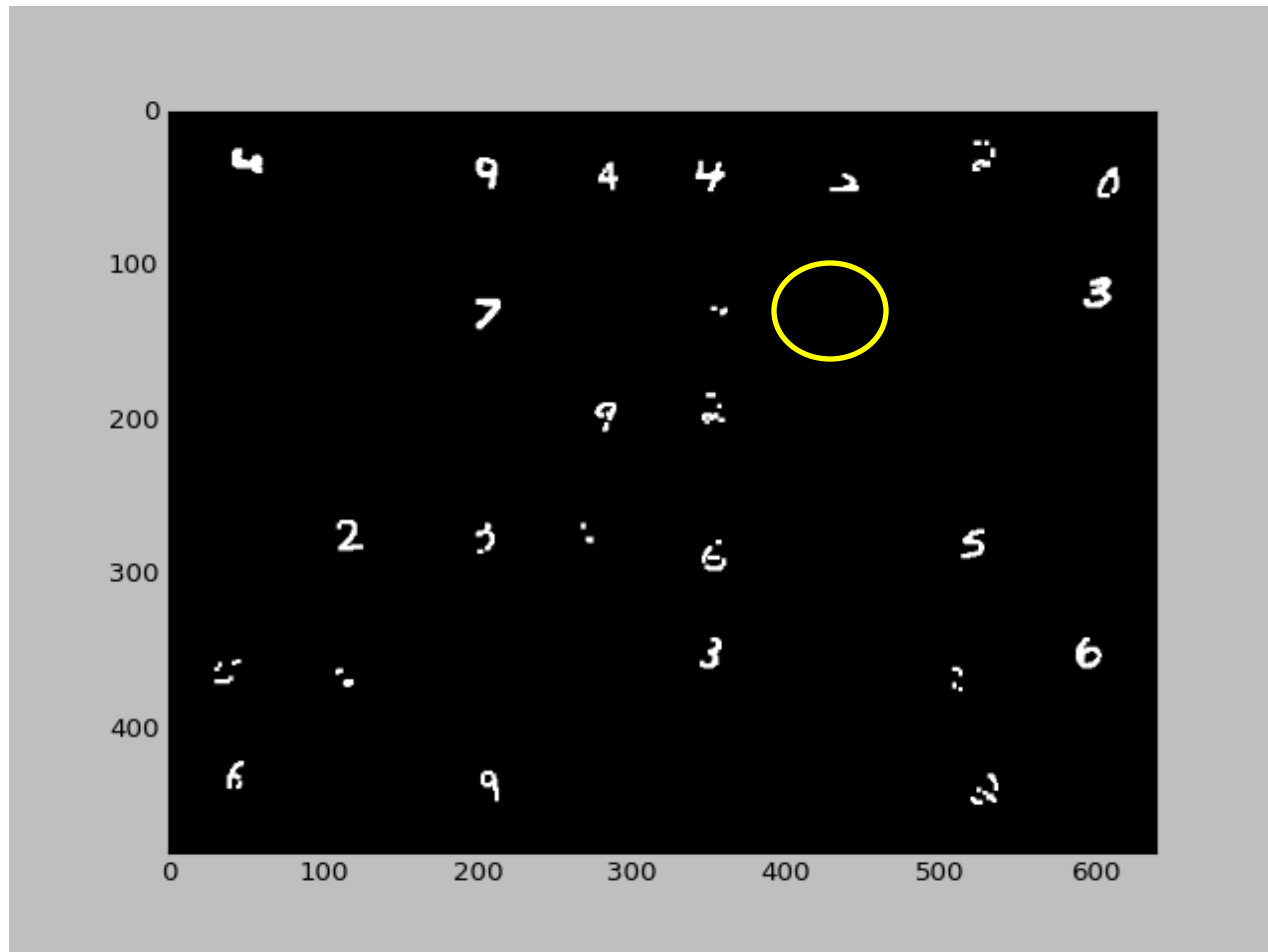
Da li dobro detektuje sve brojeve?




# Problem: uklanjanje brojeva




# Razlog: Opening square(3)




# Opening square(2)




Rešeno: uklanjanje brojeva  
Problem: ostaju tačke




Uklanjanje zelene boje: `img[:, :, 1] = 0`  
Možda ne treba opening



# Problem: ostaju tačke




# Problem: ostaju tačke







# Ostaju nijanse plave i crvene



Rešenje: povećanje threshold-a  
Problem: uništava brojeve




# Rešenje 2: opening square(2)




# Tačnost: 58%

# Da li može da se poboljša?




Prethodno: Dilation - disk(15)

Da li se može poboljšati određivanje centra?




# Problem: Dilation

disk(25)




# Problem: Dilation - disk(25)

Tačnost: 13%



# Problem: Dilation


## disk(1)









# Rešenje: Dilation diamond(5)



Tačnost: 65%




# Poboljšanje: Erosion disk(2)




Tačnost: 66%

Šta ako se promeni threshold?




Threshold > 0.03

Tačnost: 63%



Threshold > 0.13

Tačnost: 49%



# Poboljšanja


- Za threshold eksperimentalno određeno da bude  $> 0.054$
- Tačnost  $> 66\%$
- Koja još poboljšanja da se unesu?
- Nije pomeran okvir oko brojeva
- Potrebno testirati tačnost za pomeranje
- Da li zavisi koliko se pomera okvir?



# Pomeranje okvira

- Pomeranje za 2 piksela u svim pravcima daje lošije rezultate od predhodnih: od 4% do 10%
- Pomeranje za 3 piksela u svim pravcima daje još lošije rezultate
- Pomeranje za 1 piksel?

# Pomeranje za 1 piksel u svim pravcima




# Tačnost: 60%-85%

- U zavisnosti od neuronske mreže, dobija se uglavnom veća tačnost.
- Korišćen algoritam:
  - Traži se najveća verovatnoća broja kod svih slika pomeraja

```
tt = model.predict(np.array([imgB_test]), verbose=0)
t = model.predict_classes(np.array([imgB_test]), verbose=0)
if max_verovatnoca < max(tt[0]):
    max_verovatnoca = max(tt[0])
    max_broj = t[0]
```

# Pomeranje za 1 piksel dole-desno



# Tačnost: 92%

- Najveća tačnost dobijena je predstavljenom metodom.

# Drugi algoritam za određivanje verovatnoće

- Sabiranje svih verovatnoća kod slika pomeraja

```
tt = model.predict(np.array([imgB_test]), verbose=0)
tt2 = tt2 + tt[0]


max_broj = np.argmax(tt2)
```

- Tačnost: 86%

# Rezime

- Uklanjanje zelene boje
- Threshold  $> 0.054$
- Opening – square(2)
- Dilation – diamond(5)
- Erosion – disk(2)
- Određivanje regiona
- Pomeraj okvira za 1 piksel dole-desno
- Traži se najveća verovatnoća broja kod svih slika pomeraja

# Model neuronske mreže





# Model neuronske mreže

- Korišćeni model u prethodnim primerima:
  - Ulaz i izlaz u 1. sloj 784, aktivaciona funkcija “relu” (Ractifier)
  - Ulaz u 2. sloj 784, a izlaz 10, aktivaciona funkcija “softmax” (Sigmoidal)

```
#kreiranje modela
model = Sequential()
model.add(Dense(784, input_dim=784, init='normal', activation='relu'))
model.add(Dense(10, init='normal', activation='softmax'))

#compile i fit modela
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
model.fit(data, train_out, validation_data=(test_data, test_out), nb_epoch=125, batch_size=200, verbose=2)
```

<http://machinelearningmastery.com/handwritten-digit-recognition-using-convolutional-neural-networks-python-keras/>

# Model neuronske mreže


- Testirana rešenja:
  - Model sa drugim aktivacionim funkcijama – manja tačnost
  - Model sa više slojeva – manja tačnost
  - Model sa različitim izlazima za 1. sloj – manja tačnost
  - Razne kombinacije prethodno navedenog

# Model sa 25 epoha

- Obučavajući skup:
  - 5.000 MNIST slika: tačnost: 30%
  - 10.000 MNIST slika: tačnost: 47%
  - 20.000 MNIST slika: tačnost: 52%
  - 35.000 MNIST slika: tačnost: 62%
  - 60.000 MNIST slika: tačnost: 68%
  - 70.000 MNIST slika: tačnost: 82%

# Model sa 25 epoha


Tačnost



# Model sa 70.000 MNIST slika

- Broj epoha:
  - 1 epoha: tačnost: 39%
  - 2 epohe: tačnost: 52%
  - 5 epoha: tačnost: 64%
  - 10 epoha: tačnost: 83%
  - 15 epoha: tačnost: 74%
  - 20 epoha: tačnost: 83%
  - 25 epoha: tačnost: 88%
  - 125 epoha: tačnost: 92%
  - 165 epoha: tačnost: 87%

# Model sa 70.000 MNIST slika



# Napomena

- Dve različite obuke sa istim karakteristikama:
  - 70.000 MNIST slika i 25 epoha
  - Dobijene tačnosti: 82% i 88%
  - Ne moraju uvek iste vrednosti da se dobiju, zavisi od obuke neuronske mreže